Attention Is All You Need

Tác giả: Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Ł

Nguồn: Advances in Neural Information Processing Systems (NeurIPS) | Tham chiếu: https://arxiv.org/abs/17

1. TÓM TẮT NỘI DUNG NGHIÊN CỨU (ABSTRACT)

Bài báo này giới thiệu kiến trúc Transformer, một bước ngoặt trong lĩnh vực trí tuệ nhân tạo và tính toán hiện đại. Thay vì sử dụng các mạng nơ-ron tái phát (RNN) hoặc mạng nơ-ron tích chập (CNN) truyền thống để xử lý chuỗi, các tác giả đề xuất một cơ chế hoàn toàn mới dựa trên 'tự chú ý' (self-attention). Phương pháp này cho phép máy tính xử lý các thành phần của dữ liệu đầu vào một cách song song thay vì tuần tự, giúp tăng tốc độ tính toán đáng kể và cải thiện khả năng học các mối quan hệ xa trong văn bản. Công trình này đã trở thành nền tảng cho hầu hết các mô hình ngôn ngữ lớn (LLM) hiện nay như GPT, BERT, làm thay đổi hoàn toàn cách thức máy tính hiểu và tạo ra ngôn ngữ tự nhiên, đồng thời tối ưu hóa hiệu suất phần cứng đồ họa (GPU) trong huấn luyện mô hình.

2. GIÁ TRỊ HỌC THUẬT & PHƯƠNG PHÁP LUẬN (METHODOLOGY & CONTEXT)

Công trình nghiên cứu này cung cấp cơ sở lý luận khoa học và bằng chứng thực nghiệm quan trọng đối với chủ đề 'tìm bài báo về máy tính'. Toàn bộ luận điểm trong tài liệu đã được thẩm định qua quy trình bình duyệt chuyên gia (Peer-Reviewed) của Advances in Neural Information Processing Systems (NeurIPS). Tài liệu đã được thu nạp tự động, chuẩn hóa dữ liệu và lưu trữ vĩnh viễn trong Kho Tài Liệu Workspace của hệ thống Multi-Agent RAG nhằm phục vụ việc đối soát trích dẫn nguyên văn, kiểm định NLI và tổng hợp báo cáo học thuật chuyên sâu.